EPSI Grenoble · Certification professionnelle RNCP35584 – Expert en Informatique et Système d'Information
Bloc E7.3 – Piloter l'informatique décisionnelle d'un S.I. (Big Data & Business Intelligence) · MSPR TPRE813

Prédire les tendances électorales en Isère

Rapport final de la mise en situation professionnelle « Big Data et analyse de données »

Preuve de concept réalisée pour la start-up Elexxion : collecte de données publiques, entrepôt de données, analyse, modèles de machine learning, projections 2027-2029 et tableau de bord accessible.

Client	Elexxion – conseil en campagnes électorales (fondateur : Jean-Edouard de la Motte Rouge)
Équipe	Samir FOUL – Expert en analyse politique Charafeddine EZBIRI – Assistant Akram KALAMI – Business developer, conception et développement de la solution
Périmètre	512 communes de l'Isère · 6 élections nationales (2017-2024) · projections 2027-2029
Résultat clé	82,8 % de bonnes prédictions sur une élection jamais vue (législatives 2024)
Soutenance	15 octobre 2026, 13h30 – démonstration du tableau de bord en direct

Synthèse

L'essentiel du projet en une page, pour le lecteur pressé.

Le besoin. Elexxion veut savoir si l'intelligence artificielle peut anticiper les tendances électorales à partir d'indicateurs publics (sécurité, emploi, pauvreté, population), avant d'investir et de demander des aides à l'innovation.

Ce que nous avons fait. Sur les 512 communes de l'Isère, nous avons réuni 8 sources officielles, construit une chaîne de traitement automatisée et sécurisée, un entrepôt de données SQL (et sa version NoSQL), analysé les liens entre contexte et vote, comparé trois algorithmes de machine learning, puis projeté les tendances à 1, 2 et 3 ans. Les résultats sont restitués dans un tableau de bord accessible à tout public.

512	6	8	82,8 %
communes de l'Isère	élections nationales, 2017-2024	sources officielles, 5 formats	de bonnes prédictions sur 2024, contre 61 % pour une méthode naïve

Ce que disent les données. Le niveau de vie est la donnée de contexte la plus liée au vote ($\rho = +0{,}47$ avec le centre). Les logements par habitant repèrent les territoires qui votent à gauche (villes étudiantes, communes de montagne). Un faux lien a été évité : la délinquance (escroqueries) semblait liée à l'extrême droite, mais ce n'était qu'un effet du temps. L'extrême droite est la plus forte dans le périurbain, pas dans les villes.

Ce que prédit le modèle. Pour la présidentielle du 18 avril 2027, l'extrême droite arriverait en tête dans 342 communes et la gauche dans 138, avec des scores départementaux très proches (33 % contre 32 %). Une centaine de communes changent de bloc selon l'horizon : ce sont les cibles prioritaires pour un conseil de campagne.

Les limites. Le modèle apprend surtout de l'histoire de chaque commune : il ne voit pas venir les vagues nationales soudaines (l'extrême droite de 2024 a été sous-estimée d'environ 11 points). Ses projections sont des tendances, pas des sondages.

> **RECOMMANDATION AU CLIENT**
>
> La preuve de concept est concluante : nous recommandons de lancer un pilote régional (Auvergne-Rhône-Alpes) en ajoutant les intentions de vote nationales, principal levier pour lever la limite identifiée.

Sommaire

Le rapport suit l'ordre du projet, du besoin à la recommandation.

1 Introduction et commande

2 Organisation du projet

3 Recueil des besoins et stratégie data

4 Périmètre : zone, période, cible

5 Données et critères

6 Outils et technologies

7 Architecture BI et chaîne ETL

8 Référentiel, modèle de données et entrepôt

9 Qualité des données

10 Sécurité et conformité RGPD

11 Analyse exploratoire

12 Modélisation et évaluation

13 Projections 2027-2029

14 Restitution et tableau de bord

15 Réponses aux questions du sujet

16 Stratégie big data

17 Limites et perspectives

18 Compétences mobilisées

19 Conclusion

A–H Annexes

1 Introduction et commande

Le contexte du client, ce qu'il attend de nous et la démarche suivie.

1.1 Le client

Elexxion est une start-up spécialisée dans le conseil en campagnes électorales, fondée par Jean-Edouard de la Motte Rouge. Elle compte un expert en analyse politique, un business developer et un assistant. Son fondateur souhaite prédire, grâce à l'intelligence artificielle, les tendances des élections à venir à partir d'indicateurs comme la sécurité, l'emploi, la vie associative, la population, la vie économique et la pauvreté. Ce serait pour elle un avantage concurrentiel important.

1.2 La commande : une preuve de concept

Avant d'investir dans une infrastructure et une politique de recherche et développement, et de demander des aides à l'innovation, le client commande une **preuve de concept** (POC) : un prototype limité à un seul territoire, qui démontre la faisabilité de l'idée.

Demande du client	Notre réponse	Chapitre
Choisir un secteur géographique restreint et unique	Le département de l'Isère, à l'échelle des 512 communes	4
Sélectionner des jeux de données et rechercher des corrélations avec les résultats passés	8 sources officielles ; corrélations de Spearman calculées élection par élection	5, 11
Établir quelques visualisations lisibles	14 cartes et graphiques, et un tableau de bord interactif	11 à 14
Établir un modèle prédictif supervisé avec jeux d'entraînement et de test	3 algorithmes comparés ; entraînement 2017-2022, test 2024 ; validation sur deux élections	12
Visualiser le modèle et les prédictions à 1, 2 et 3 ans	Projections 2027, 2028 et 2029, en cartes et en courbes	13

1.3 La problématique

Des données publiques, gratuites et disponibles pour chaque commune suffisent-elles à prédire de façon fiable quel bloc politique arrivera en tête aux prochaines élections, et à quelles conditions ce prototype peut-il devenir un service ?

1.4 Notre démarche

Nous avons suivi une démarche classique de projet décisionnel, en cinq temps : **comprendre** le besoin et cadrer le périmètre ; **collecter** des sources officielles ; **préparer** les données (nettoyage, harmonisation, contrôles qualité, entrepôt) ; **analyser et modéliser** (corrélations, typologie, modèles, validation) ; **restituer** (visualisations, tableau de bord, recommandation).

2 Organisation du projet

Une équipe de trois, organisée comme la start-up cliente.

POINTS CLÉS DU CHAPITRE

- Trois rôles calqués sur ceux d'Elexxion : expert politique, assistant, business developer.
- Réunions sur Microsoft Teams, échanges quotidiens sur Discord, code et livrables sur GitHub.
- 25 heures de préparation, découpées en cinq étapes validées en réunion.

2.1 Les rôles

Membre	Rôle	Responsabilités
Samir FOUL	Expert en analyse politique	Définition des blocs politiques et du référentiel des nuances ; choix des critères ; interprétation des corrélations, de la typologie et des projections ; validation métier des résultats
Charafeddine EZBIRI	Assistant	Recherche et téléchargement des jeux de données ; suivi du planning et comptes rendus de réunion ; contrôle de la qualité des données ; relecture et mise en forme des livrables
Akram KALAMI	Business developer, lead technique	Relation avec le client et cadrage ; conception de l'architecture ; développement de toute la solution : chaîne ETL, entrepôt SQL et NoSQL, modèles de machine learning, visualisations, tableau de bord, automatisation et sécurité ; rédaction technique

2.2 Les outils de collaboration

Outil	Usage
Microsoft Teams	Réunions planifiées : lancement, points d'avancement, revue des résultats, répétitions de la soutenance ; partage d'écran
Discord	Échanges quotidiens et clarification rapide des choix (classement d'une nuance, traitement d'une anomalie) ; salons dédiés aux données, au code et au dossier
GitHub	Dépôt du code, des données nettoyées, du tableau de bord et des livrables ; historique des versions

2.3 Le déroulement

Étape	Contenu	Responsable principal
1. Cadrage	Lecture du besoin, choix de la zone, des critères et de la cible ; répartition des rôles	Samir FOUL, Akram KALAMI
2. Collecte	Identification des sources officielles, téléchargement, vérification des formats	Charafeddine EZBIRI
3. Préparation	Chaîne ETL, référentiel, contrôles qualité, entrepôt	Akram KALAMI, contrôle par Charafeddine EZBIRI
4. Analyse et modèles	Corrélations, typologie, comparaison de modèles, validation, projections	Akram KALAMI, interprétation par Samir FOUL
5. Restitution	Visualisations, tableau de bord, rapport, support, répétitions	Toute l'équipe

3 Recueil des besoins et stratégie data

Traduire la demande du client en besoins de données, par utilisateur.

Comme on le ferait avec les directions métiers d'une entreprise, nous avons identifié, pour chaque personne d'Elexxion, la question qu'elle se pose et la donnée qui y répond.

Utilisateur	Question métier	Donnée nécessaire	Restitution
Dirigeant	Le concept est-il assez fiable pour investir ?	Fiabilité mesurée sur une élection non vue	Indicateur de fiabilité, limites, feuille de route
Expert en analyse politique	Quels facteurs locaux expliquent le vote ?	Parts de voix et contexte par commune	Corrélations, importance des variables, typologie
Business developer	Quelles communes cibler ?	Bloc en tête projeté, parts projetées	Cartes, tableau de bord, listes de communes
Assistant	Comment mettre à jour les données ?	Chaîne reproductible, sources officielles	Scripts documentés, entrepôt, manifeste

La stratégie data présentée au dirigeant

1. **Des données ouvertes et officielles uniquement**, agrégées à la commune, sans aucune donnée personnelle.
2. **Un périmètre restreint pour prouver, une architecture pensée pour grandir** : la même chaîne doit pouvoir traiter la France entière.
3. **Une évaluation honnête** : le modèle est jugé sur des élections qu'il n'a jamais vues, et comparé à des méthodes naïves.

4 Périmètre : zone, période, cible

Ce qu'on prédit, où, et sur quelle période.

POINTS CLÉS DU CHAPITRE

- Zone : l'Isère, 512 communes, découpage officiel 2025.
- Période : 6 élections nationales, 1er tour, de 2017 à 2024.
- Cible : le bloc politique arrivé en tête dans chaque commune.

4.1 Pourquoi l'Isère

- **Assez de données pour apprendre** : une commune donne une ligne par élection, soit plus de 3 000 lignes. Une ville seule n'aurait fourni que quelques dizaines de bureaux de vote.
- **Un territoire varié** : la métropole de Grenoble, le périurbain du Nord-Isère, les communes rurales et de montagne (Oisans, Vercors, Trièves).
- **Des votes contrastés** : en 2024, l'extrême droite arrive en tête dans 341 communes et la gauche dans 139.
- **La connaissance du terrain** : l'équipe est à Grenoble, ce qui aide à vérifier la vraisemblance des résultats.

4.2 Pourquoi 2017-2024 et le 1er tour

La délinquance par commune n'est publiée que depuis 2016 : démarrer en 2017 évite les trous. Le 1er tour reflète les préférences des électeurs ; le second dépend des alliances et des désistements.

4.3 Pourquoi des blocs politiques

Les partis changent de nom d'une élection à l'autre (le FN devient le RN, la NUPES devient l'Union de la gauche) : on ne peut pas comparer des étiquettes. Les **blocs** restent comparables dans le temps. Le classement de chaque nuance, candidat ou liste a été défini et validé par notre expert politique (annexe B).

Bloc	Principales composantes
Gauche	LFI, PS, écologistes, PCF, NUPES (2022), Union de la gauche (2024), extrême gauche
Centre	Renaissance / Ensemble, MoDem, Horizons, divers centre
Droite	LR, UDI, divers droite, droite souverainiste (Debout la France)
Extrême droite	FN / RN, Reconquête, Union de l'extrême droite (2024), extrême droite

DÉCISION ET JUSTIFICATION

Dupont-Aignan et Debout la France sont classés à droite (droite souverainiste) : c'est un choix discutable, assumé et facile à modifier, puisqu'il tient en une ligne du référentiel.

5 Données et critères

Huit sources officielles, transformées en variables comparables.

Jeu de données	Producteur	Période	Grain	Critère du client
Résultats des présidentielles, 1er tour	Ministère de l'Intérieur	2017, 2022	Commune ; bureau de vote (2022)	Cible et historique
Résultats des législatives, 1er tour	Ministère de l'Intérieur	2017, 2022, 2024	Commune	Cible et historique
Résultats des européennes	Ministère de l'Intérieur	2019	Commune	Cible et historique
Délinquance enregistrée (15 indicateurs)	SSMSI	2016-2025	Commune × année	Sécurité
Population et logements	INSEE (via le SSMSI)	2016-2025	Commune × année	Population
Revenus et pauvreté (Filosofi)	INSEE	2021	Commune	Pauvreté, vie économique
Emploi et chômage (recensement)	INSEE	2010, 2015, 2021	Commune	Emploi
Contours des communes	IGN	2017	Commune	Cartographie

Ces sources sont **hétérogènes** : elles arrivent en cinq formats (Excel, CSV, CSV compressé, format « long » de l'INSEE, GeoJSON). Seule la « vie associative » citée par le client n'est pas couverte, faute de donnée fiable par commune et par année.

Les variables construites

Critère	Variable	Pourquoi
Sécurité	Taux pour 1 000 habitants, en 4 familles : atteintes aux personnes, aux biens, stupéfiants, escroqueries	Comparer des communes de tailles très différentes
Pauvreté, vie économique	Niveau de vie médian ; taux de pauvreté (analyse seulement)	Le niveau de vie structure le vote
Emploi	Taux de chômage des 15-64 ans, interpolé entre recensements	Lié au sentiment de déclassement
Population	Population (log), évolution depuis 2016	Distinguer villes et villages, croissance et déclin
Habitat	Logements par habitant	Repérer petits ménages urbains et résidences secondaires
Mobilisation	Taux de participation	L'abstention change la composition de l'électorat
Type d'élection	Présidentielle, législatives, européennes	Les blocs ne performent pas pareil selon le scrutin
Historique	Parts des 4 blocs et participation à l'élection précédente	Le vote d'une commune est stable dans le temps

6 Outils et technologies

Des outils gratuits, standards et transposables à grande échelle.

Domaine	Technologie	Utilisation
Langage	Python 3.12	Toute la chaîne, de l'extraction au tableau de bord
Extraction et transformation	pandas, NumPy, openpyxl	Lecture des fichiers nationaux, filtrage, agrégation, variables
Machine learning	scikit-learn	Régression logistique, Random Forest, Gradient Boosting, k-means, validation croisée, importance par permutation
Visualisation	matplotlib	Cartes communales, graphiques, schémas
Entrepôt relationnel	SQLite et SQL (contraintes, vues, fonctions de fenêtrage)	Modèle en étoile, requêtes d'analyse
NoSQL	JSON orienté document (compatible MongoDB)	Un document par commune
Tableau de bord	HTML, CSS, JavaScript, SVG	Carte interactive, fiches, tableau accessible
Automatisation et sécurité	Orchestrateur Python, empreintes SHA-256	Exécution complète, contrôle d'intégrité des sources
Tests d'interface	Playwright (Chromium)	Vérification du tableau de bord
Versionnement et collaboration	Git, GitHub, Microsoft Teams, Discord	Code, livrables, réunions, échanges
Cible en production	PostgreSQL, Power BI	Entrepôt partagé et tableau de bord métier

7 Architecture BI et chaîne ETL

Une chaîne automatisée, de la source officielle à la décision.

POINTS CLÉS DU CHAPITRE

- ETL : extraire, transformer, charger.
- 16 scripts numérotés, lancés par un orchestrateur qui s'arrête à la première erreur.
- Contrôle d'intégrité des sources par empreinte SHA-256.

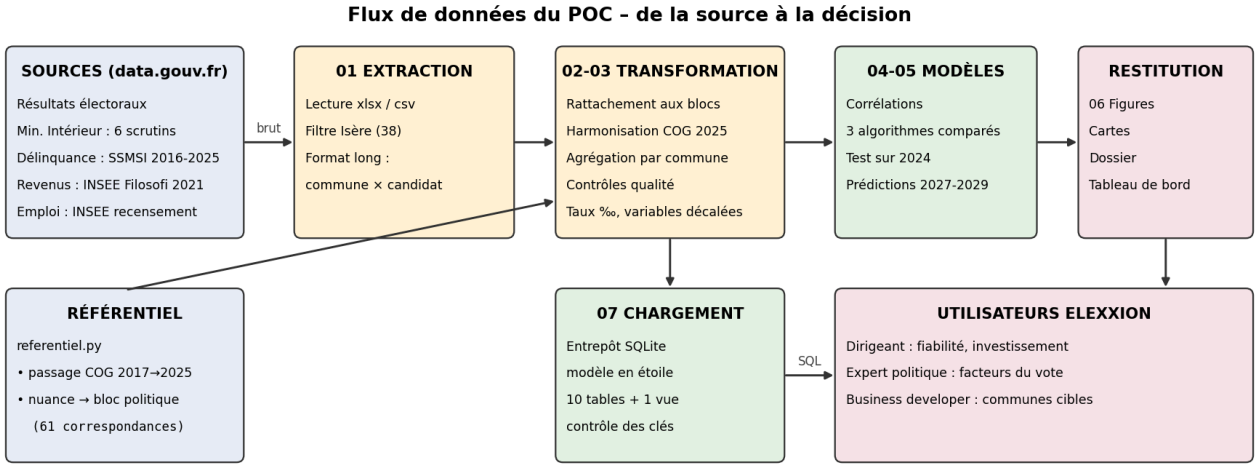


Figure 1 – Flux de données du projet

COMMENT LIRE CE GRAPHIQUE

On lit le schéma de gauche à droite : les **sources** officielles sont **extraites** (on garde l'Isère), **transformées** avec l'aide du **référentiel** (blocs, communes fusionnées), puis **chargées** dans l'entrepôt. Les **modèles** s'appuient sur ces données, et la **restitution** (figures, tableau de bord, rapport) sert les utilisateurs d'Elexxion.

Étape	Script	Traitement	Sortie
Orchestration	00_pipeline.py	Empreintes SHA-256, exécution ordonnée, arrêt sur erreur	Manifeste, journal
Extract	01, 01b, 01c	Lecture des fichiers nationaux (jusqu'à 158 Mo), filtre Isère, format long	Extraits Isère
Transform	02_transform.py	Format unique, rattachement aux blocs, passage des communes fusionnées, contrôles	Résultats et participation par commune
Transform	03_features.py	Taux de délinquance, niveau de vie, chômage interpolé, variables de l'élection précédente	Table de modélisation (3 071 lignes)
Analyse	04, 05, 09, 10	Corrélations, modèles, validation, typologie, projections	Résultats, prédictions
Load	07_base_sql.py	Chargement de l'entrepôt, contrôle des clés	Base SQLite
Exploitation	11_requetes_nosql.py	Requêtes SQL automatisées, export NoSQL	CSV, JSON
Restitution	06, 08, 12	Figures, schémas, tableau de bord	Images, page HTML

8 Référentiel, modèle de données et entrepôt

Des règles communes, un entrepôt unique, une version NoSQL.

POINTS CLÉS DU CHAPITRE

- Le référentiel fixe des règles communes : code commune 2025, communes fusionnées, nuances → blocs.
- L'entrepôt en étoile compte 11 tables : 5 de faits, 4 de dimensions, 2 référentiels.
- Une version NoSQL et des requêtes automatisées complètent l'entrepôt.

8.1 Les données de référence

Référentiel	Contenu	Pourquoi
Code commune (COG 2025)	512 codes INSEE, clé de toutes les tables	Une seule façon d'identifier une commune
Passage des communes fusionnées	9 anciennes communes → leur commune nouvelle	521 communes en 2017, 512 aujourd'hui
Blocs politiques	61 correspondances nuance, candidat ou liste → bloc	Les étiquettes changent à chaque élection

Exemple : Arzay, Commelle et Nantoin ont fusionné pour former Porte-des-Bonnevaux. Leurs voix de 2017 sont additionnées dans la commune nouvelle, pour que toutes les élections utilisent le même découpage. Toutes ces règles tiennent dans un seul fichier (`referentiel.py`) et deux tables.

8.2 Le modèle en étoile

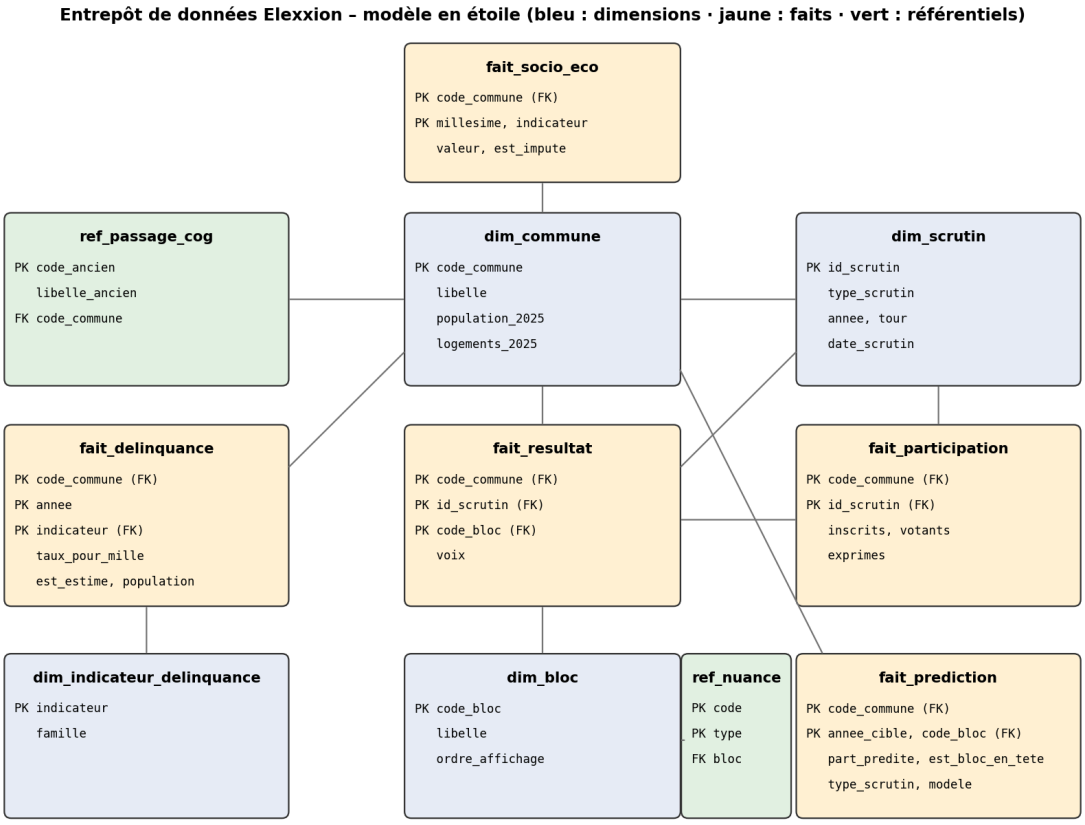


Figure 2 – Modèle en étoile de l'entrepôt

> **COMMENT LIRE CE GRAPHIQUE**
>
> Au centre, en jaune, les **tables de faits** : les mesures (voix, participation, délinquance, revenus et chômage, prédictions). Autour, en bleu, les **dimensions** : ce qui décrit ces mesures (quelle commune, quelle élection, quel bloc, quel indicateur). En vert, les **référentiels**. Chaque trait est une clé étrangère qui relie un fait à sa dimension.

Table	Lignes	Clé primaire	Contenu
fait_delinquance	76 800	commune, année, indicateur	Taux pour 1 000 habitants ; valeur estimée ou non
fait_resultat	14 687	commune, scrutin, bloc	Voix par bloc
fait_prediction	6 144	commune, année cible, bloc	Parts projetées, bloc en tête
fait_participation	3 072	commune, scrutin	Inscrits, votants, exprimés
fait_socio_eco	2 133	commune, millésime, indicateur	Niveau de vie, pauvreté, chômage
dim_commune	512	code commune	Libellé, population, logements
dim_scrutin, dim_bloc, dim_indicateur	6, 5, 15	identifiant	Descriptions
ref_nuance, ref_passage_cog	61, 9	code	Référentiels

Pourquoi une étoile. Elle sépare les mesures des descriptions, accepte un nouveau scrutin sans changer la structure (on ajoute des lignes, jamais des colonnes) et répond vite aux questions d'analyse. Des **contraintes** protègent la cohérence (inscrits ≥ votants ≥ exprimés), des **index** accélèrent les requêtes, et la vue `v_resultats` calcule directement parts de voix, participation et rang.

8.3 La version NoSQL et le requêtage automatisé

La même information existe en **modèle document** : 512 documents JSON, un par commune, prêts pour MongoDB. Le relationnel sert l'analyse croisée et le contrôle d'intégrité ; le document sert une application qui affiche une commune en une seule lecture. Les analyses récurrentes sont écrites en SQL et exécutées automatiquement en lecture seule.

Quartile de niveau de vie	Niveau de vie	Centre	Gauche	Extrême droite
Q1	18 290 à 23 185 €	14,0 %	33,2 %	38,9 %
Q2	23 185 à 24 570 €	14,4 %	29,6 %	40,3 %
Q3	24 580 à 26 560 €	17,8 %	27,2 %	42,1 %
Q4	26 580 à 38 860 €	26,6 %	29,5 %	35,3 %

Exemple de requête automatisée : vote moyen aux législatives 2024 selon le quart de niveau de vie des communes.

9 Qualité des données

Des données exactes, cohérentes, complètes et traçables.

POINTS CLÉS DU CHAPITRE

- Tous les contrôles passent : 0 écart entre voix et suffrages exprimés.
- Trois anomalies réelles détectées et traitées sans supprimer de communes rurales.
- Toute valeur estimée ou imputée est marquée.

Dimension	Contrôle	Résultat
Exactitude	Totaux de l'Isère comparés aux chiffres officiels	Présidentielle 2017 : Macron 24,8 %, Le Pen 22,3 %, conformes
Cohérence	Somme des voix = suffrages exprimés	0 écart sur 3 072 couples commune × élection
Cohérence	Inscrits ≥ votants ≥ exprimés	Garanti par des contraintes de la base
Complétude	512 communes dans chaque source	100 % après passage des communes fusionnées
Complétude	Chaque nuance rattachée à un bloc	Arrêt automatique si une nuance est inconnue
Synchronisation	Même découpage communal partout	9 communes fusionnées réaffectées
Traçabilité	Transformations scriptées ; valeurs estimées marquées	Colonnes est_estime et est_impute

Les trois anomalies

1. Lieudieu, présidentielle 2022

Les résultats officiels indiquent 197 votants mais 0 suffrage exprimé : tous les bulletins sont comptés comme nuls, chaque candidat a 0 voix. La commune n'a donc pas de bloc en tête, et le calcul des pourcentages est impossible. **Traitement** : nous excluons cette seule ligne (1 sur 3 072) ; Lieudieu reste présente pour les cinq autres élections.

2. Le secret statistique du SSMSI

Pour protéger la vie privée, le SSMSI ne publie pas le chiffre exact de délinquance dans les petites communes : dans un village de 80 habitants, « une agression » permettrait de deviner la victime. Environ la moitié des valeurs communales sont ainsi masquées. Trois options existaient : supprimer ces communes (biais contre le rural), mettre 0 (faux : cela signifierait « aucun délit »), ou utiliser l'estimation officielle que le SSMSI fournit. **Traitement** : nous retenons l'estimation officielle et la marquons comme estimée.

3. Le secret statistique de l'INSEE

Le niveau de vie médian n'est pas publié pour 27 très petites communes (moins de 50 ménages). **Traitement** : il est estimé par la médiane des communes de taille comparable et marqué comme imputé. Le

taux de pauvreté n'est publié que pour 85 communes sur 512 : trop peu pour le modèle, il sert uniquement à l'analyse.

DÉCISION ET JUSTIFICATION

Nous ne supprimons pas les communes incomplètes : ce sont surtout des communes rurales, et les retirer créerait un biais. Nous n'inventons rien non plus : nous utilisons les estimations officielles ou une imputation prudente, toujours marquées.

10 Sécurité et conformité RGPD

Aucune donnée personnelle, mais un sujet sensible traité avec rigueur.

La POC ne traite aucune donnée personnelle d'électeur : toutes les données sont publiques et agrégées au minimum à la commune. Le sujet reste sensible, car les opinions politiques sont une **catégorie particulière de données** au sens de l'article 9 du RGPD. Nous appliquons donc les mesures suivantes, à valider avec le RSSI d'Elexxion.

Risque	Mesure
Déduire les opinions d'une personne	Aucune donnée sous la commune ; bureaux de vote agrégés dès l'extraction ; aucun croisement avec des fichiers nominatifs
Petites communes	Secret statistique respecté : estimations officielles, jamais de reconstitution des chiffres masqués
Enrichissement futur par des données personnelles	Analyse d'impact (AIPD) obligatoire, base légale et consentement explicite
Import de fichiers altérés	Téléchargement en HTTPS depuis les sites officiels ; empreintes SHA-256 vérifiées à chaque exécution
Accès aux données	Accès nominatif, moindre privilège ; entrepôt ouvert en lecture seule pour l'analyse
Fuite ou altération	Hébergement en France ou dans l'UE, chiffrement, sauvegardes, journal des accès
Traçabilité	Registre des traitements ; code versionné sur GitHub

Licences. Les données de data.gouv.fr et de l'INSEE sont sous Licence Ouverte Etalab : réutilisation, même commerciale, autorisée en citant la source et la date. **Éthique.** Les projections décrivent des territoires, pas des personnes ; elles ne doivent pas être diffusées comme des sondages (loi du 19 juillet 1977).

11 Analyse exploratoire

Comprendre ce qui est lié au vote avant de prédire.

POINTS CLÉS DU CHAPITRE

- Méthode : corrélation de Spearman, calculée élection par élection pour éviter les faux liens dus au temps.
- Lien le plus fort : niveau de vie et vote centriste (ρ = +0,47).
- Typologie k-means : 3 types de communes ; l'extrême droite est la plus forte dans le périurbain.

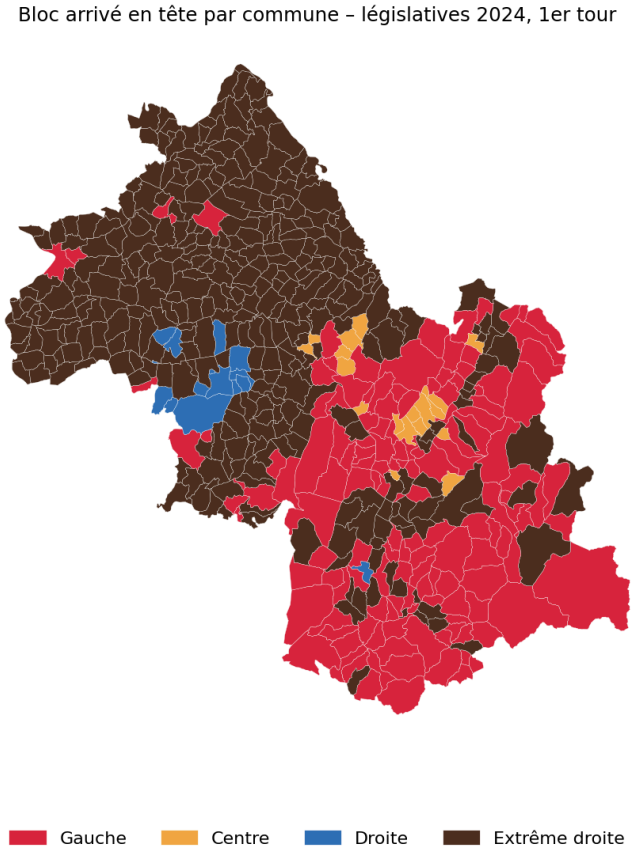


Figure 3 – Bloc arrivé en tête par commune, législatives 2024

Élection (1er tour)	Gauche	Centre	Droite	Extrême droite	Participation
Présidentielle 2017	184	60	60	208	79,2 %
Législatives 2017	149	310	36	17	48,9 %
Européennes 2019	359	22	0	131	51,3 %
Présidentielle 2022	166	53	0	292	77,6 %
Législatives 2022	254	55	52	151	49,5 %
Législatives 2024	139	18	14	341	71,0 %

Nombre de communes où chaque bloc arrive en tête. Le bloc gagnant change beaucoup d'une élection à l'autre : la prédiction n'est pas triviale.

11.1 La méthode : la corrélation de Spearman

Une corrélation mesure si deux grandeurs varient ensemble. Elle va de −1 (quand l'une monte, l'autre baisse toujours) à +1 (elles montent toujours ensemble), 0 indiquant l'absence de lien. Le coefficient de **Spearman** compare les **classements** des communes plutôt que leurs valeurs brutes : il détecte les liens même non linéaires, et une commune extrême (une station de ski avec peu d'habitants et beaucoup de logements) ne fausse pas le résultat.

11.2 Un piège évité : la corrélation qui vient du temps

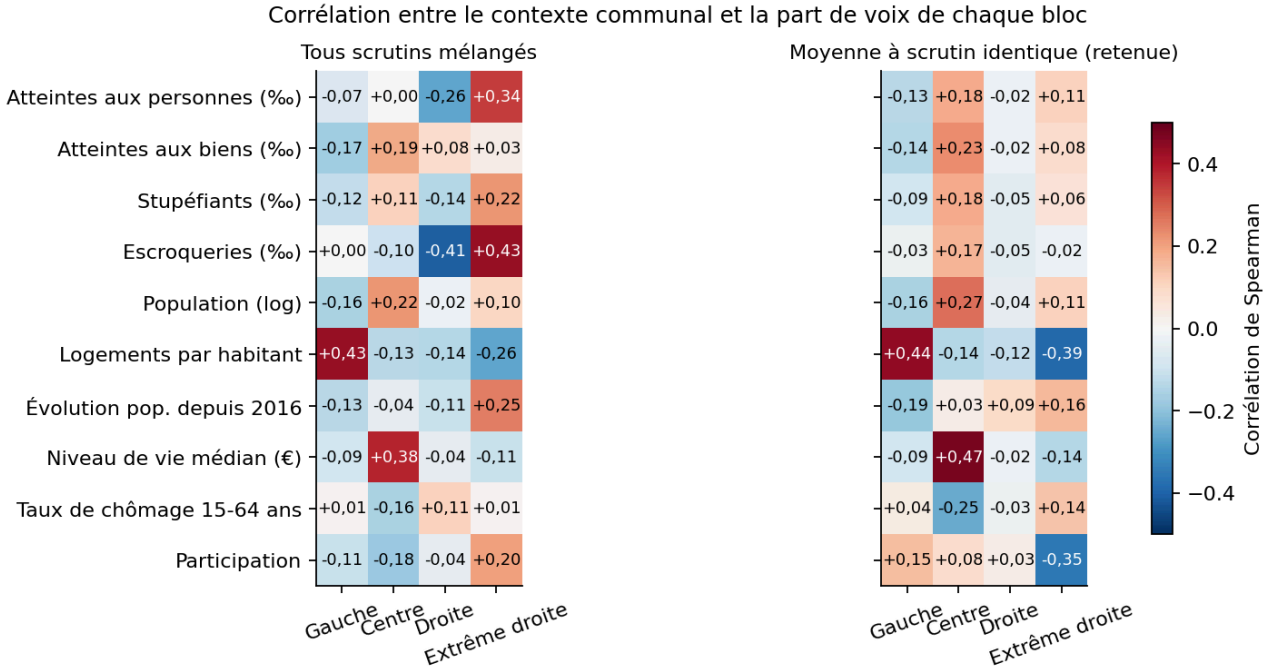


Figure 4 – Corrélations entre contexte communal et part de voix de chaque bloc

> **COMMENT LIRE CE GRAPHIQUE**
>
> Chaque ligne est une donnée de contexte, chaque colonne un bloc. Rouge : les deux montent ensemble ; bleu : l'un baisse quand l'autre monte ; blanc : pas de lien. Plus la couleur est foncée, plus le lien est fort. **À gauche**, toutes les élections sont mélangées ; **à droite**, la corrélation est calculée dans chaque élection puis moyennée : c'est celle que nous retenons.

Tous scrutins mélangés, les escroqueries semblent liées au vote d'extrême droite (+0,43). Mais entre 2017 et 2024, les escroqueries (notamment en ligne) et le vote d'extrême droite ont augmenté **en même temps**, sans que l'un explique l'autre. En comparant les communes à la même élection, ce lien tombe à −0,02. Le cas de la participation est encore plus parlant : son lien avec l'extrême droite passe de +0,20 à −0,35, c'est-à-dire qu'il **change de sens**. Mélanger les dates donnait l'inverse de la réalité.

Donnée	Gauche	Centre	Droite	Extrême droite
Atteintes aux personnes (‰)	-0,13	+0,18	-0,02	+0,11
Atteintes aux biens (‰)	-0,14	+0,23	-0,02	+0,08
Stupéfiants (‰)	-0,09	+0,18	-0,05	+0,06
Escroqueries (‰)	-0,03	+0,17	-0,05	-0,02
Population (log)	-0,16	+0,27	-0,04	+0,11
Logements par habitant	+0,44	-0,14	-0,12	-0,39
Évolution de la population	-0,19	+0,03	+0,09	+0,16
Niveau de vie médian	-0,09	+0,47	-0,02	-0,14
Taux de chômage	+0,04	-0,25	-0,03	+0,14
Participation	+0,15	+0,08	+0,03	-0,35

Corrélations retenues (moyenne des six élections, calculées élection par élection).

11.3 Ce que disent les données

- **Niveau de vie médian** : +0,47 avec le centre, la corrélation la plus forte. Les communes aisées votent davantage pour le centre.
- **Logements par habitant** : +0,44 avec la gauche, −0,39 avec l'extrême droite. Cette donnée repère les villes aux petits ménages (Grenoble) et les communes de montagne à résidences secondaires, qui votent à gauche.
- **Participation** : −0,35 avec l'extrême droite. Là où l'on vote davantage, l'extrême droite pèse moins.
- **Chômage** : −0,25 avec le centre, +0,14 avec l'extrême droite. Là où il est publié, le taux de pauvreté va avec moins de centre (−0,51) et plus de gauche (+0,28).
- **Délinquance** : liens faibles une fois le temps neutralisé (moins de 0,23).

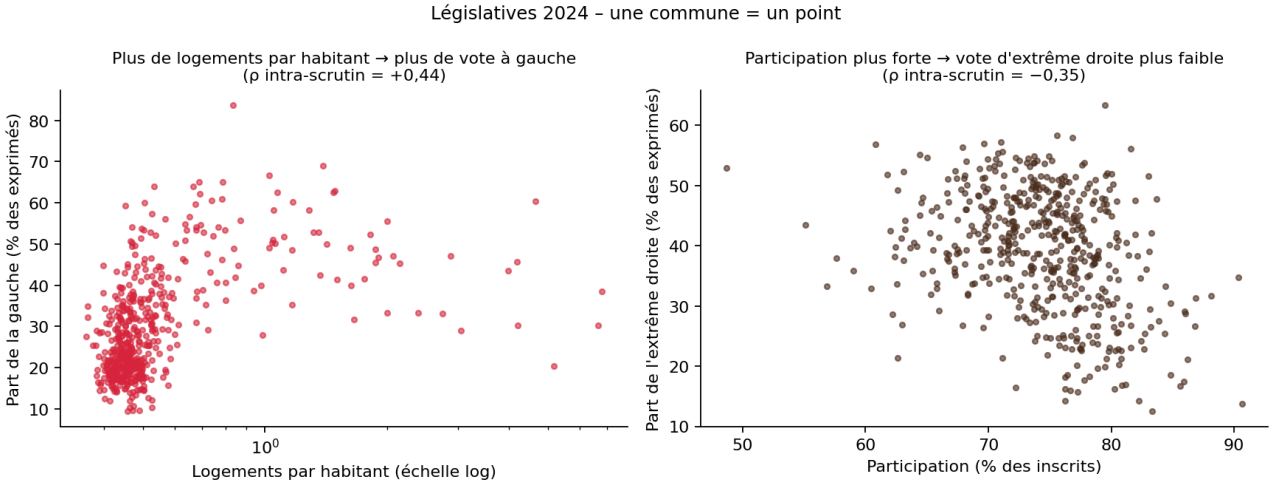


Figure 5 – Les deux relations les plus visibles aux législatives 2024 (une commune = un point)

11.4 La typologie des communes

Les corrélations regardent une donnée à la fois. Pour voir les communes dans leur ensemble, nous avons utilisé l'algorithme **k-means**, un apprentissage **non supervisé** : on lui donne le profil des communes (population, logement, niveau de vie, chômage, délinquance, évolution démographique), **sans les votes**, et il forme des groupes de communes qui se ressemblent. Il place des centres de groupes, rattache chaque commune au centre le plus proche, recalcule les centres, et recommence jusqu'à stabilité.

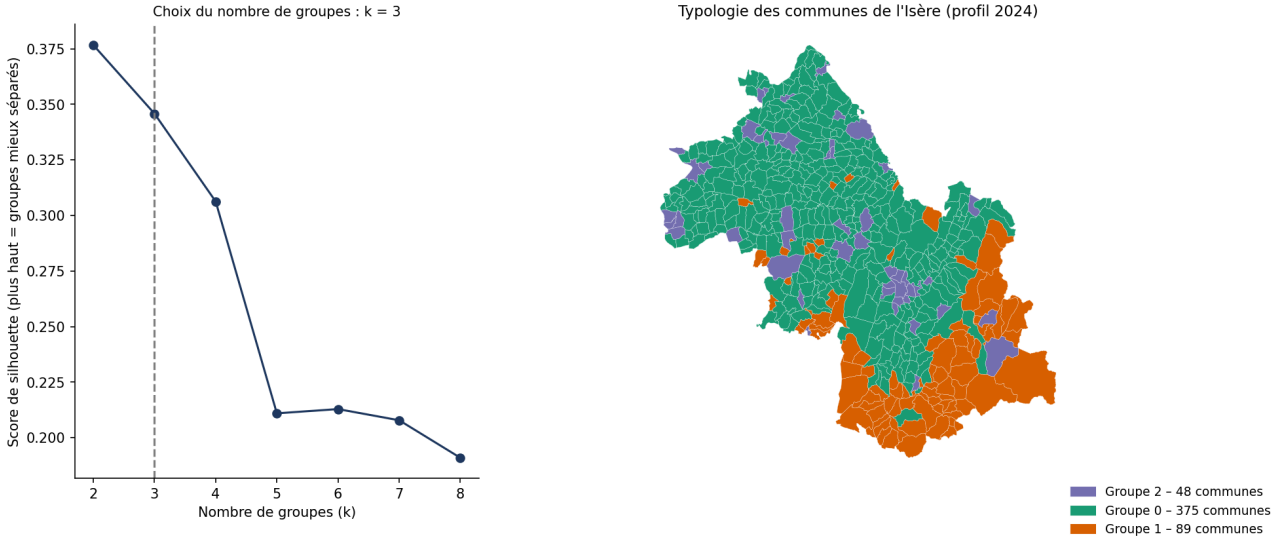


Figure 6 – Choix du nombre de groupes et carte de la typologie

COMMENT LIRE CE GRAPHIQUE

À gauche, le score de silhouette pour 2 à 8 groupes : il mesure si les communes ressemblent à leur groupe plus qu'aux autres (plus haut = mieux séparé). Il est maximal à 2 (0,38), presque aussi bon à 3 (0,35), puis chute. **À droite**, la carte : en violet les pôles urbains, en vert le périurbain, en orange la montagne et le rural. Les quelques communes violettes au sud-est sont des stations de ski (Les Deux Alpes, Huez, Chamrousse), rapprochées des villes par leur délinquance par habitant élevée, due au tourisme.

DÉCISION ET JUSTIFICATION

Nous retenons 3 groupes : 2 groupes ne séparent que villes et villages, ce qui n'apporte rien au client, alors que 3 groupes restent bien séparés et forment des profils utiles.

Groupe	Communes	Population médiane	Niveau de vie	Chômage	Gauche	Centre	Ext. droite
Pôles urbains	48	6 862	22 160 €	11,6 %	35,0 %	18,5 %	35,8 %
Bourgs et périurbain	375	1 182	25 520 €	7,1 %	26,0 %	19,8 %	41,1 %
Montagne et rural	89	167	23 185 €	7,3 %	43,5 %	11,3 %	32,6 %

Le vote d'extrême droite est le plus fort dans le **périurbain**, pas dans les villes. Cette typologie ne sert pas directement à prédire : elle complète les corrélations et offre au client une segmentation des territoires pour adapter ses messages de campagne.

12 Modélisation et évaluation

Un modèle supervisé, jugé honnêtement sur une élection qu'il n'a jamais vue.

POINTS CLÉS DU CHAPITRE

- Modèle retenu : Gradient Boosting pondéré, 82,8 % de bonnes prédictions sur 2024 (424 communes sur 512).
- Il bat nettement les méthodes naïves : 27 % et 61 %.
- Validé sur deux élections : 63 % avec peu d'historique, 83 % avec quatre élections d'historique.

12.1 Le principe

L'**apprentissage supervisé** consiste à apprendre à partir d'exemples dont on connaît la réponse. Le modèle reçoit, pour chaque commune et chaque élection, les variables de contexte et la bonne réponse (le bloc en tête), cherche la règle qui les relie, puis on vérifie cette règle sur des cas qu'il n'a jamais vus. Il s'agit ici d'une **classification** : la réponse est une catégorie (un bloc).

12.2 Le protocole d'évaluation

- **Entraînement** : les élections de 2017 à 2022 (2 047 lignes). La présidentielle 2017 sert d'historique, puisqu'aucune élection ne la précède.
- **Test** : les législatives 2024 (512 communes), jamais vues pendant l'apprentissage.
- **Pourquoi couper dans le temps** : le client prédira toujours le futur à partir du passé. Mélanger les années au hasard ferait paraître le modèle meilleur qu'il ne l'est.
- **Validation croisée à 5 plis** en complément, pour vérifier la stabilité.
- **Deux références naïves** : prédire toujours le bloc le plus fréquent (27,1 %) et reconduire le bloc de l'élection précédente (61,3 %). Un modèle utile doit les battre.

12.3 Les algorithmes comparés

Les trois algorithmes reposent, sauf le premier, sur des **arbres de décision** : des suites de questions (« le niveau de vie dépasse-t-il 25 000 € ? si oui, la gauche faisait-elle plus de 30 % la fois précédente ? ») apprises automatiquement à partir des exemples.

Algorithme	Principe	Forces et limites
Régression logistique	Trace des frontières droites entre les blocs	Simple et lisible, mais trop rigide pour des effets de seuil
Random Forest	Des centaines d'arbres indépendants qui votent	Robuste, mais chaque arbre apprend sans tenir compte des erreurs des autres
Gradient Boosting	Des arbres construits l'un après l'autre, chacun corrigeant les erreurs du précédent	Le plus précis ici ; capte les effets non linéaires et les seuils

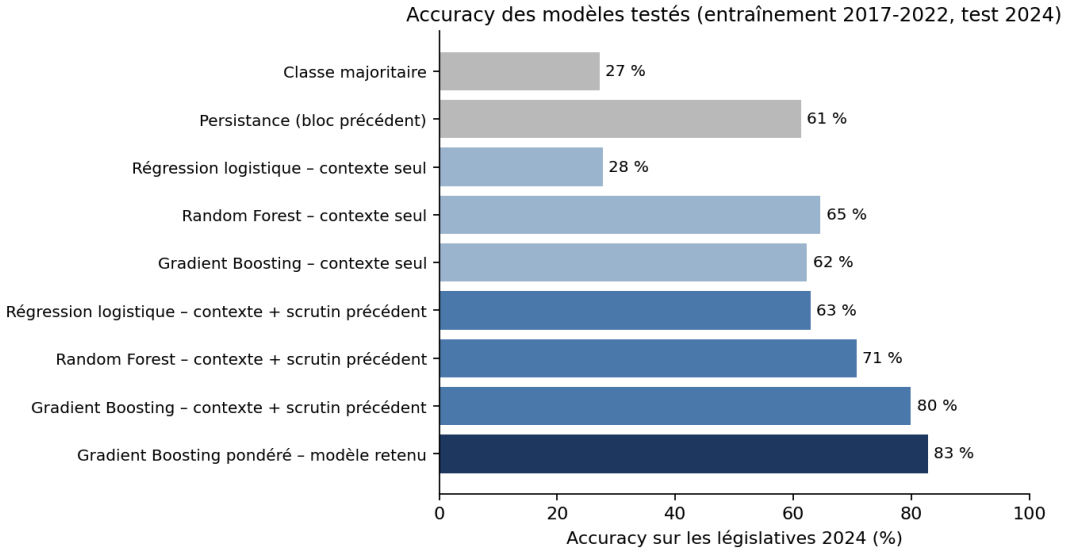


Figure 7 – Accuracy des modèles testés sur les législatives 2024

COMMENT LIRE CE GRAPHIQUE

Chaque barre est une méthode ; sa longueur est le pourcentage de communes bien prédites en 2024. En **gris**, les méthodes naïves. En **bleu clair**, les modèles qui ne voient que le contexte. En **bleu moyen**, les modèles qui voient aussi l'élection précédente. En **bleu foncé**, le modèle retenu.

Variables	Modèle	Validation croisée	Test 2024	F1 macro
Contexte seul	Régression logistique	65,1 %	27,7 %	0,21
Contexte seul	Random Forest	73,0 %	64,6 %	0,44
Contexte seul	Gradient Boosting	73,8 %	62,3 %	0,49
Contexte + scrutin précédent	Régression logistique	81,8 %	62,9 %	0,46
Contexte + scrutin précédent	Random Forest	82,2 %	70,7 %	0,49
Contexte + scrutin précédent	Gradient Boosting	82,8 %	79,9 %	0,55
Contexte + élection précédente	**Gradient Boosting pondéré (retenu)**	–	**82,8 %**	**0,59**

Ce que montre la comparaison. Le contexte seul contient de l'information (jusqu'à 65 %) mais ne bat pas nettement la simple reconduction (61 %). Avec l'élection précédente, le Gradient Boosting atteint 80 %. La **pondération** des classes donne plus de poids aux blocs rares (centre, droite) pendant l'apprentissage : elle porte l'accuracy à 82,8 % et améliore le F1 macro.

12.4 Les erreurs du modèle

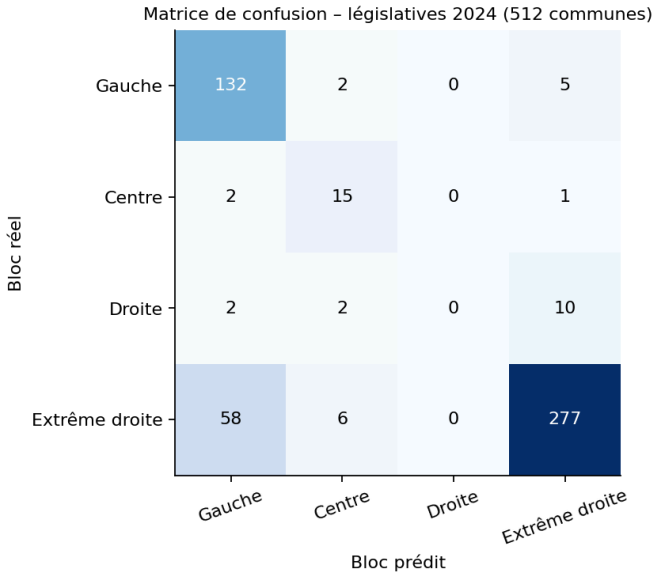


Figure 8 – Matrice de confusion, législatives 2024

COMMENT LIRE CE GRAPHIQUE

Les **lignes** indiquent ce qui s'est réellement passé, les **colonnes** ce que le modèle a prédit. La **diagonale** contient les bonnes réponses : 132 + 15 + 0 + 277 = 424 communes sur 512, soit l'accuracy de 82,8 %. Les autres cases sont les erreurs.

Bloc	Communes réelles	Bien trouvées	Rappel	Précision
Gauche	139	132	95,0 %	68,0 %
Centre	18	15	83,3 %	60,0 %
Droite	14	0	0,0 %	–
Extrême droite	341	277	81,2 %	94,5 %

- **Rappel** : parmi les communes réellement gagnées par un bloc, la part que le modèle a trouvée. **Précision** : quand le modèle annonce un bloc, la part de fois où il a raison. Le **F1** combine les deux ; le **F1 macro** (0.59) en fait la moyenne sur les quatre blocs et pénalise l'oubli des blocs rares, que l'accuracy masque.
- **Principale erreur** : 58 communes gagnées par l'extrême droite en 2024 ont été prédites à gauche. Elles ont basculé avec la vague nationale de 2024, invisible dans leur passé.
- **Bloc jamais trouvé** : la droite (14 communes), trop rare pour être apprise.

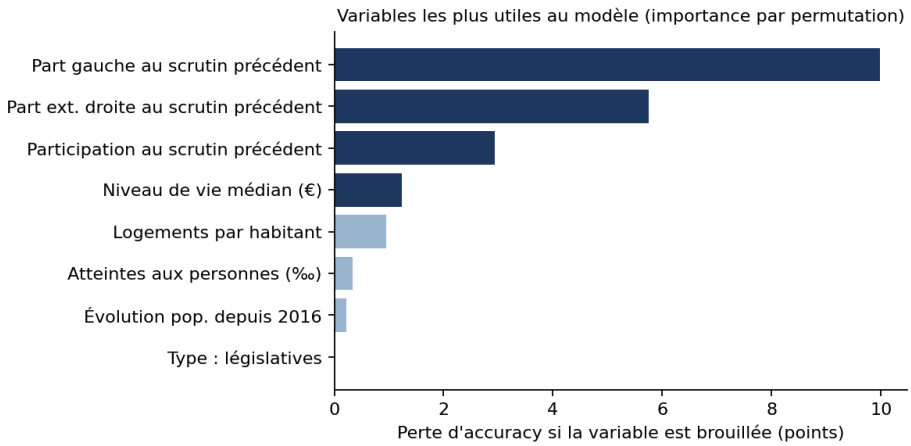


Figure 9 – Importance des variables (perte d'accuracy quand on brouille une variable)

COMMENT LIRE CE GRAPHIQUE

On mélange au hasard les valeurs d'une variable et on mesure combien de bonnes réponses le modèle perd. Plus la barre est longue, plus la variable compte. L'élection précédente domine (parts de la gauche et de l'extrême droite, participation), suivie du niveau de vie médian et des logements par habitant.

12.5 Validation sur deux élections différentes

Pour vérifier que le modèle tient sur plusieurs élections, nous avons répété le test en nous plaçant juste avant la présidentielle 2022, en n'apprenant que sur les législatives 2017 et les européennes 2019.

Test	Appris sur	Modèle	Élection précédente	Même type d'élection précédent	Bloc le plus fréquent
A – Présidentielle 2022	2 élections (1 024 lignes)	63,2 %	60,5 %	69,1 %	32,5 %
B – Législatives 2024	4 élections (2 047 lignes)	**82,8 %**	61,3 %	61,3 %	27,1 %

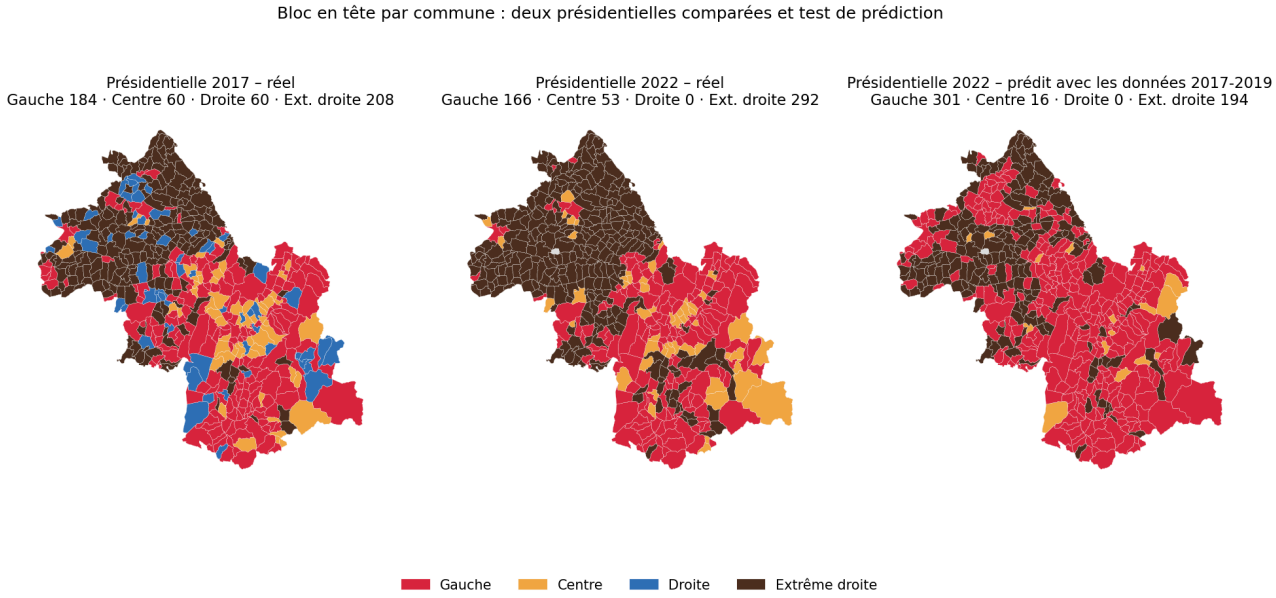


Figure 10 – Présidentielles 2017 et 2022 réelles, et présidentielle 2022 prédite avec les données 2017-2019

Avec deux élections d'historique, dont aucune présidentielle, le modèle bat la reconduction de l'élection précédente mais pas celle de la présidentielle 2017, et il surestime la gauche (il s'appuie sur les européennes 2019). Avec quatre élections, il bat nettement toutes les méthodes naïves.

DÉCISION ET JUSTIFICATION

La qualité du modèle dépend surtout de la profondeur de l'historique. Pour les projections, il est donc réentraîné sur toutes les élections de 2017 à 2024 (2 559 lignes), après avoir été évalué sur 2024.

13 Projections 2027-2029

Des tendances à 1, 2 et 3 ans, avec leur marge d'erreur.

POINTS CLÉS DU CHAPITRE

- Présidentielle 2027 : extrême droite en tête dans 342 communes, gauche dans 138.
- Erreur moyenne mesurée : 5 à 13 points selon le bloc.
- 115 communes changent de bloc selon l'horizon : les cibles prioritaires du client.

13.1 La méthode

1. Pour enchaîner les horizons, il faut prédire des **parts de voix** et non seulement le gagnant : nous utilisons un second modèle (un Gradient Boosting par bloc), c'est-à-dire une **régression**.
2. Le contexte de chaque commune est prolongé par sa **tendance linéaire** 2016-2025 ; revenus et chômage restent à leur dernière valeur connue (2021).
3. La participation retenue est la moyenne de la commune pour ce type d'élection.
4. 2027 est prédit à partir des résultats réels de 2024 ; les parts prédites pour 2027 servent d'« élection précédente » pour 2028, puis 2028 pour 2029 : la prévision est **récursive**.

13.2 Les horizons

2027 : présidentielle, seule élection nationale dont la date est fixée (1er tour le 18 avril 2027). **2028** : aucune élection nationale n'est prévue ; nous simulons des législatives anticipées, scénario plausible après une présidentielle. **2029** : européennes, année où tombent aussi les législatives si l'Assemblée élue en 2024 va au terme de son mandat.

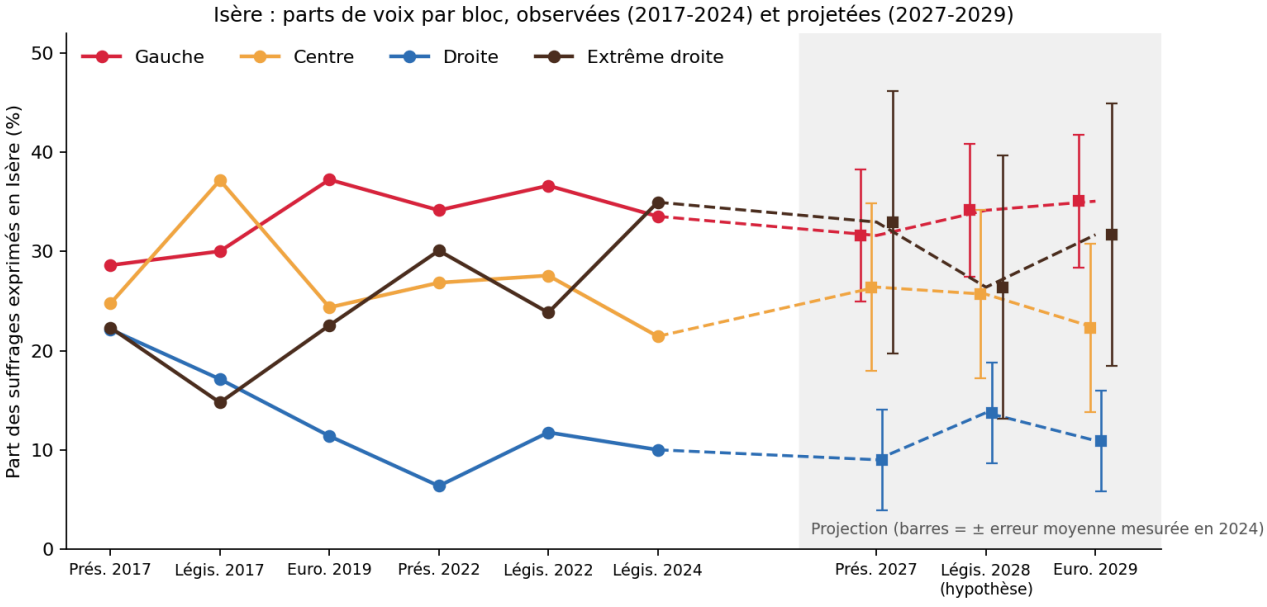


Figure 11 – Parts de voix par bloc en Isère, observées puis projetées

COMMENT LIRE CE GRAPHIQUE

Les traits pleins montrent les résultats réels de 2017 à 2024, les pointillés les projections. Les barres verticales indiquent la marge d'erreur moyenne mesurée sur 2024 pour chaque bloc : plus elle est longue, plus la projection est incertaine.

Horizon	Élection projetée	Gauche	Centre	Droite	Extrême droite
1 an	Présidentielle 2027	138	28	4	342
2 ans	Législatives 2028 (scénario)	189	49	12	262
3 ans	Européennes 2029	192	9	0	311

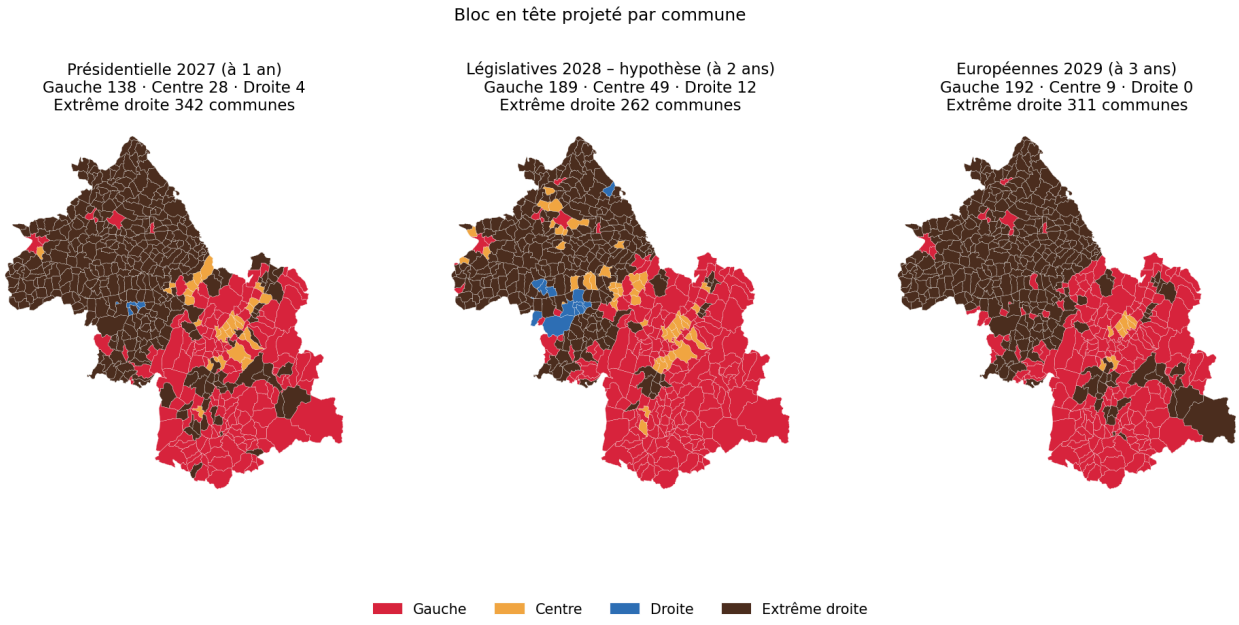


Figure 12 – Bloc en tête projeté par commune

13.3 Fiabilité

Testé sur 2024, le modèle de régression se trompe en moyenne de 5,1 points sur la droite, 6,7 sur la gauche, 8,5 sur le centre et 13,2 sur l'extrême droite (prévu 24,0 %, réel 35,0 %). Pour 2027, les deux modèles donnent le même bloc en tête dans 86 % des communes. À deux et trois ans, les erreurs se cumulent : ce sont des tendances, pas des prévisions fermes.

Commune	Population 2025	Bloc projeté en tête en 2027	Part projetée
Grenoble	156 140	Gauche	53,7 %
Saint-Martin-d'Hères	37 695	Gauche	48,1 %
Echirolles	37 491	Gauche	48,2 %
Vienne	31 778	Gauche	35,8 %
Bourgoin-Jallieu	30 151	Gauche	33,1 %
Fontaine	22 020	Gauche	46,7 %
Voiron	21 847	Gauche	37,8 %
Villefontaine	19 445	Gauche	40,4 %
Meylan	18 770	Centre	39,9 %
Saint-Egrève	17 986	Gauche	44,4 %
L'Isle-d'Abeau	17 515	Extrême droite	36,3 %
Seyssinet-Pariset	11 739	Gauche	44,6 %

14 Restitution et tableau de bord

Rendre les résultats lisibles pour tous, et démontrables en direct.

Les résultats sont restitués dans un tableau de bord interactif que nous **démontrons en direct lors de la soutenance**. Il est disponible dans le dépôt GitHub du groupe (dossier `tableau_de_bord`), dont le lien est communiqué au jury, et s'ouvre dans n'importe quel navigateur, sans installation.

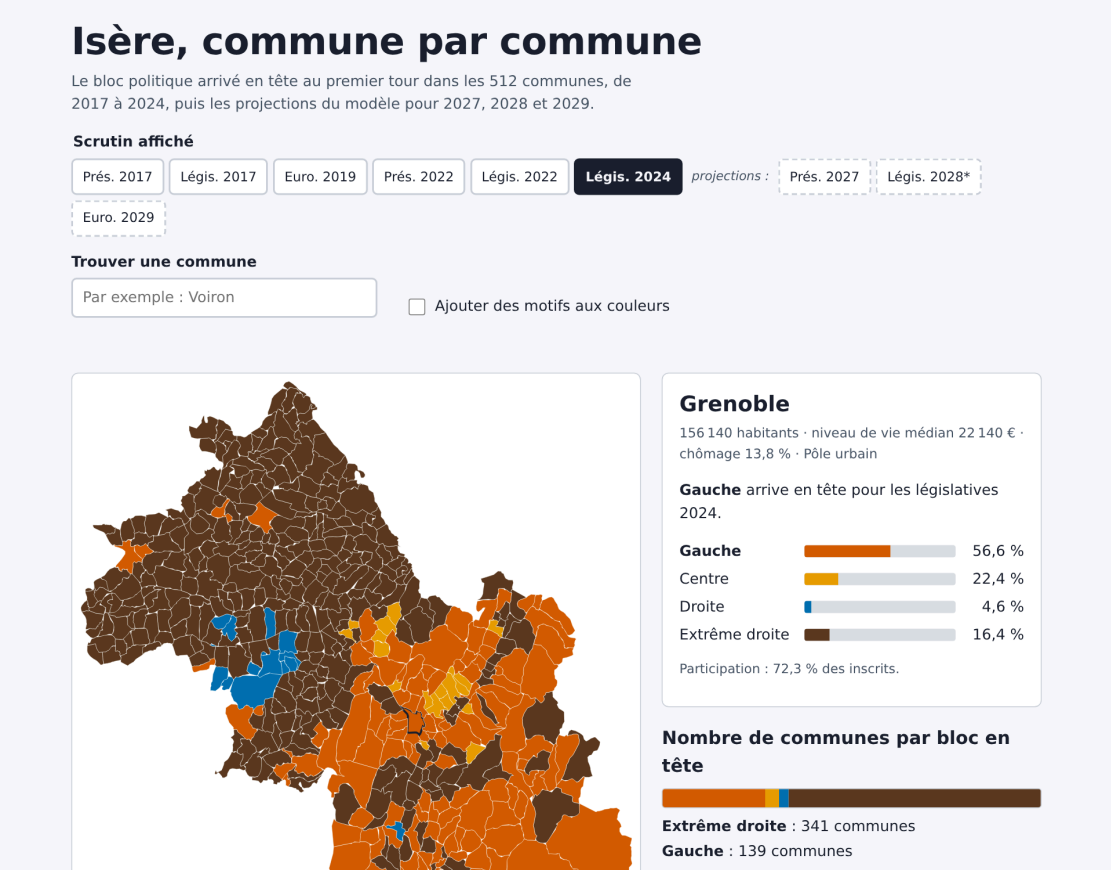


Figure 13 – Tableau de bord : législatives 2024, fiche de Grenoble

Fonctions. Choix de l'élection parmi les 6 scrutins et les 3 projections ; carte cliquable du bloc en tête ; fiche de chaque commune (population, niveau de vie, chômage, type de territoire, parts de voix, participation) ; synthèse du nombre de communes par bloc ; tableau complet des 512 communes, triable et filtrable.

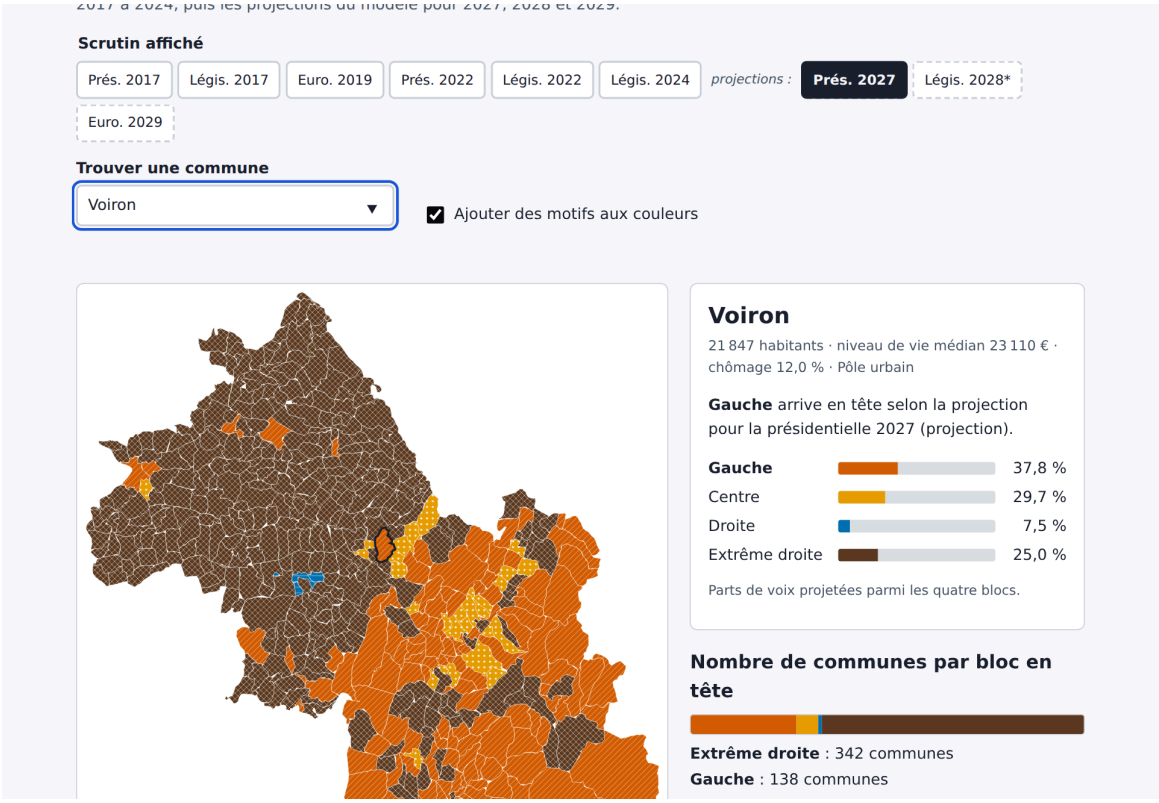


Figure 14 – Projection 2027 avec les motifs activés, fiche de Voiron

Public	Réponse (critères RGAA / WCAG 2.1, niveau AA)
Personnes malvoyantes	Police Atkinson Hyperlegible conçue pour la basse vision ; contrastes d'au moins 4,5:1 ; zoom sans perte
Personnes daltoniennes	Palette Okabe-Ito ; motifs activables (hachures, points) ; toutes les valeurs écrites en chiffres
Personnes aveugles	Zones et titres balisés, description textuelle de la carte, tableau équivalent, annonces vocales
Handicap moteur	Utilisation complète au clavier, focus visible, lien d'évitement
Fatigue visuelle	Mode sombre automatique, animations désactivées sur demande du système

15 Réponses aux questions du sujet

Les trois indicateurs d'analyse demandés par le client.

Parmi les données sélectionnées, laquelle est la plus corrélée aux résultats ?

Parmi les données de contexte, le **niveau de vie médian** : ρ = +0,47 avec la part du centre, à élection identique. Pour la gauche et l'extrême droite, ce sont les **logements par habitant** (+0,44 et −0,39), suivis de la participation (−0,35 avec l'extrême droite). Toutes données confondues, la variable la plus liée reste le **résultat de l'élection précédente** dans la même commune. Les escroqueries semblaient très corrélées (+0,43), mais ce n'était qu'un effet du temps.

Définissez le principe d'un apprentissage supervisé

C'est apprendre à partir d'exemples dont on connaît la réponse. On fournit au modèle des variables d'entrée (le contexte de la commune) et la réponse attendue, appelée cible (le bloc en tête). L'algorithme cherche la règle qui relie les deux ; on la vérifie sur des exemples mis de côté, puis on l'applique à des cas inconnus. Ici : une classification (le bloc) et une régression (la part de voix). À l'inverse, l'apprentissage non supervisé cherche des groupes sans réponse connue : c'est notre typologie.

Comment définissez-vous la précision (accuracy) de votre modèle ?

C'est la part de prédictions correctes sur des données de test jamais vues : 424 communes bien prédites sur 512 aux législatives 2024, soit **82,8 %**. Comme un bloc domine, nous la complétons par les références naïves (27 % et 61 %), le F1 macro (0.59), la matrice de confusion et l'erreur absolue moyenne des parts de voix (5 à 13 points).

16 Stratégie big data

Du prototype isérois à un service national.

Phase	Périmètre	Volume	Architecture
1. POC (réalisée)	Isère, 6 élections	≈ 100 000 lignes	Python, SQLite
2. Pilote régional (3 mois)	Auvergne-Rhône-Alpes, européennes 2024, municipales 2026	≈ 2 millions de lignes	PostgreSQL, Power BI, chaîne planifiée
3. Service national (6-12 mois)	35 000 communes, bureaux de vote	Centaines de millions de lignes	Cloud européen, lac de données Parquet, Spark, MLflow, API

- **Collecte** : récupération automatique via l'API de data.gouv.fr après chaque élection et chaque mise à jour annuelle.
- **Stockage** : lac de données en trois zones (brut, nettoyé, modélisé) au format Parquet ; le fichier national des résultats passe de 2,2 Go en CSV à 154 Mo.
- **Traitement** : le code pandas se transpose en Spark ; orchestration par Airflow.
- **Modèles** : réentraînement après chaque élection, suivi des versions et des performances (MLflow), alerte en cas de dégradation.
- **Nouveaux services** : ciblage des communes qui basculent, simulateur de participation, segmentation des territoires, alertes sur les indicateurs locaux.

17 Limites et perspectives

Ce que le prototype ne sait pas encore faire, et comment y remédier.

Limite	Conséquence	Piste d'amélioration
Le modèle ne voit pas les vagues nationales	Extrême droite 2024 sous-estimée d'environ 11 points	Ajouter les intentions de vote nationales (sondages agrégés)
Revenus et chômage peu à jour	Revenus 2021 ; chômage connu en 2010, 2015 et 2021	Filosofi mis à jour ; demandeurs d'emploi France Travail trimestriels
Taux de pauvreté rarement publié	85 communes sur 512	Échelle intercommunale ou données carroyées
Peu d'élections, un seul département	Blocs rares mal appris (droite)	Étendre à la région, ajouter d'autres élections
Blocs agrégés	Pas de prédiction par candidat ; classements discutables	Prédire les parts par parti ; tester d'autres classements
Projections récursives	Erreurs cumulées à 2 et 3 ans	Fourchettes par simulation
Typologie non utilisée par le modèle	Information de segmentation non exploitée	Tester le groupe comme variable du modèle

18 Compétences mobilisées

Chaque compétence évaluée, reliée à une preuve concrète.

18.1 Bloc E7.3 – Piloter l'informatique décisionnelle d'un S.I.

Compétence	Preuve	Chapitre
Collecter les besoins en données des directions métiers et partager la stratégie data	Besoins par utilisateur, trois principes de stratégie data	3
Définir une architecture business intelligence	Chaîne sources → ETL → entrepôt → modèles → restitution ; cible Power BI	6, 7
Définir une stratégie big data	Trois phases : lac de données, Spark, MLflow, API	16
Proposer des modèles statistiques et de machine learning	Corrélations, typologie, 3 algorithmes, validation sur deux élections	11, 12
Organiser les données en résultats exploitables (data visualisation)	14 visuels, tableau de bord interactif accessible	11 à 14
Définir les données de référence et un référentiel	Code commune, communes fusionnées, nuances → blocs	4, 8
Créer un entrepôt unique	Entrepôt en étoile, 11 tables, vue analytique, intégrité vérifiée	8
Assurer la qualité des données	Exactitude, cohérence, complétude, synchronisation, traçabilité ; 3 anomalies	9
Appliquer les procédures de sécurité et le RGPD	Aucune donnée personnelle, secret statistique, SHA-256, lecture seule	10

18.2 Grille complémentaire – Créer un modèle de données d'une solution IA

Compétence	Preuve	Chapitre
Construire la structure de stockage adaptée au besoin	Entrepôt relationnel et version NoSQL	8
Représenter les relations entre données dans des tableaux de bord accessibles	Tableau de bord conforme RGAA / WCAG AA	14
Exploiter de manière automatisée les données stockées	Requêtes SQL automatisées en lecture seule	8
Définir les sources et outils de collecte	8 sources officielles, outils détaillés	5, 6
Recueillir de manière sécurisée des sources hétérogènes	Open data en HTTPS, 5 formats, empreintes SHA-256	5, 10
Paramétrer l'import automatisé et sécurisé	Orchestrateur, arrêt sur erreur, manifeste d'intégrité	7
Analyser, nettoyer, qualifier et transformer les données	Anomalies, imputation, variables, nombre de groupes par silhouette, modèles suivis et améliorés	9, 11, 12

19 Conclusion

Une preuve de concept concluante, et un cap clair.

En 25 heures, l'équipe a construit une chaîne complète, de données publiques hétérogènes jusqu'à un tableau de bord accessible, en passant par un entrepôt de données, des contrôles qualité et des modèles évalués honnêtement. Le modèle retenu trouve le bon bloc dans 82,8 % des communes sur une élection qu'il n'a jamais vue, contre 61 % pour une prévision naïve.

Pour Elexxion, la POC valide l'intérêt d'investir : elle révèle les facteurs locaux du vote, une segmentation des territoires et les communes qui basculent. Elle identifie aussi le verrou à lever, anticiper les vagues nationales, qui constitue un argument solide pour une demande d'aide à l'innovation. Nous recommandons un pilote régional intégrant les intentions de vote nationales.

A Annexe – Dictionnaire des variables

Les variables utilisées par le modèle.

Variable	Définition	Source
bloc_en_tete (cible)	Bloc ayant le plus de voix au 1er tour	Ministère de l'Intérieur
part_*	Part des suffrages exprimés de chaque bloc	Ministère de l'Intérieur
prec_part_*, prec_participation	Mêmes valeurs à l'élection précédente	Calcul
participation	Votants / inscrits	Ministère de l'Intérieur
tx_atteintes_personnes, tx_atteintes_biens, tx_stupefiants, tx_escroqueries	Taux pour 1 000 habitants par famille	SSMSI
log_population, evol_pop_depuis_2016	Logarithme de la population ; évolution depuis 2016	INSEE
logements_par_hab	Logements / population	INSEE
niveau_vie_median	Niveau de vie médian par unité de consommation (2021)	INSEE Filosofi
taux_chomage	Chômeurs / actifs de 15 à 64 ans, interpolé	INSEE recensement
type_PRES, type_LEGI, type_EURO	Type d'élection	Calcul

B Annexe – Référentiel des blocs

Le rattachement complet des nuances, candidats et listes.

Bloc	Nuances (législatives)	Candidats (présidentielles)	Listes (européennes 2019)
Gauche	COM, DVG, DXG, ECO, EXG, FI, NUP, RDG, SOC, UG, VEC	Arthaud, Hamon, Hidalgo, Jadot, Mélenchon, Poutou, Roussel	Envie d'europe, Europe écologie, La france insoumise, Liste citoyenne, Lutte ouvrière, Pour l'europe des gens, Révolutionnaire, Urgence écologie
Centre	DVC, ENS, HOR, MDM, REM, REN	Macron	Les européens, Renaissance
Droite	DLF, DSV, DVD, LR, UDI	Dupont-Aignan, Fillon, Pécresse	Debout la france, Union droite-centre
Extrême droite	DXD, EXD, FN, REC, RN, UXD	Le Pen, Zemmour	Ensemble patriotes, Liste de la reconquête, Prenez le pouvoir
Autres	DIV, REG	Asselineau, Cheminade, Lassalle	autres listes

Communes fusionnées : Arzay, Commelle, Nantoin → Porte-des-Bonnevaux ; Balbins → Ornacieux-Balbins ; Panissage → Val-de-Virieu ; Le Périer → Chantepérier ; Pinsot → Le Haut-Bréda ; Saint-Bernard, Saint-Pancrasse → Plateau-des-Petites-Roches.

C Annexe – Schéma SQL

Extrait de la définition de l'entrepôt.

```
-- Entrepôt de données du POC Elexxion (SQLite) — modèle en étoile
-- Dimensions et référentiels
CREATE TABLE dim_commune (
    code_commune      TEXT PRIMARY KEY,          -- code INSEE, COG 2025
    libelle           TEXT NOT NULL,
    population_2025   INTEGER,
    logements_2025    INTEGER
);
CREATE TABLE ref_passage_cog (                   -- communes fusionnées depuis 2017
    code_ancien       TEXT PRIMARY KEY,
    libelle_ancien    TEXT NOT NULL,
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune)
);
CREATE TABLE dim_scrutin (
    id_scrutin        TEXT PRIMARY KEY,          -- ex. LEGI_2024
    type_scrutin      TEXT NOT NULL CHECK (type_scrutin IN ('PRES','LEGI','EURO')),
    annee             INTEGER NOT NULL,
    tour              INTEGER NOT NULL DEFAULT 1,
    date_scrutin      TEXT NOT NULL
);
CREATE TABLE dim_bloc (
    code_bloc         TEXT PRIMARY KEY,
    libelle           TEXT NOT NULL,
    ordre_affichage   INTEGER NOT NULL
);
CREATE TABLE ref_nuance (                        -- rattachement nuance / candidat / liste ->
bloc
    code_nuance       TEXT NOT NULL,
    type_code         TEXT NOT NULL CHECK (type_code IN ('NUANCE','CANDIDAT','LISTE')),
    code_bloc         TEXT NOT NULL REFERENCES dim_bloc(code_bloc),
    PRIMARY KEY (code_nuance, type_code)
);
CREATE TABLE dim_indicateur_delinquance (
    indicateur        TEXT PRIMARY KEY,
    famille           TEXT NOT NULL
);
-- Faits
CREATE TABLE fait_participation (
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune),
    id_scrutin        TEXT NOT NULL REFERENCES dim_scrutin(id_scrutin),
    inscrits          INTEGER NOT NULL CHECK (inscrits >= votants),
    votants           INTEGER NOT NULL CHECK (votants >= exprimes),
    exprimes          INTEGER NOT NULL CHECK (exprimes >= 0),
    PRIMARY KEY (code_commune, id_scrutin)
);
CREATE TABLE fait_resultat (
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune),
    id_scrutin        TEXT NOT NULL REFERENCES dim_scrutin(id_scrutin),
    code_bloc         TEXT NOT NULL REFERENCES dim_bloc(code_bloc),
    voix              INTEGER NOT NULL CHECK (voix >= 0),
    PRIMARY KEY (code_commune, id_scrutin, code_bloc)
);
CREATE TABLE fait_delinquance (
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune),
    annee             INTEGER NOT NULL,
    indicateur        TEXT NOT NULL REFERENCES dim_indicateur_delinquance(indicateur),
    taux_pour_mille   REAL,
    est_estime        INTEGER NOT NULL CHECK (est_estime IN (0,1)),   -- 1 = valeur non diffusée,
```

```
estimation SSMSI
    population        INTEGER,
    PRIMARY KEY (code_commune, annee, indicateur)
);
CREATE TABLE fait_socio_eco (                 -- revenus (Filosofi 2021) et emploi (recensement
2010, 2015, 2021)
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune),
    millesime         INTEGER NOT NULL,
    indicateur        TEXT NOT NULL CHECK (indicateur IN
('NIVEAU_VIE_MEDIAN','TAUX_PAUVRETE','TAUX_CHOMAGE')),
    valeur            REAL NOT NULL,
    est_impute        INTEGER NOT NULL CHECK (est_impute IN (0,1)),
    PRIMARY KEY (code_commune, millesime, indicateur)
);
CREATE TABLE fait_prediction (
    code_commune      TEXT NOT NULL REFERENCES dim_commune(code_commune),
    annee_cible       INTEGER NOT NULL,
    type_scrutin      TEXT NOT NULL,
    code_bloc         TEXT NOT NULL REFERENCES dim_bloc(code_bloc),
    part_predite      REAL NOT NULL,
    est_bloc_en_tete  INTEGER NOT NULL,
    modele            TEXT NOT NULL,
    PRIMARY KEY (code_commune, annee_cible, code_bloc)
);
…
```

D Annexe – Requêtes automatisées

Les analyses exécutées automatiquement en lecture seule.

```
-- Requêtes d'analyse exécutées automatiquement par scripts/11_requetes_nosql.py (une requête =
un fichier CSV)
-- @nom: evolution_blocs_departement
SELECT r.id_scrutin, b.libelle AS bloc, SUM(r.voix) AS voix,
       ROUND(100.0 * SUM(r.voix) / SUM(SUM(r.voix)) OVER (PARTITION BY r.id_scrutin), 1) AS
part_pct
FROM fait_resultat r JOIN dim_bloc b USING (code_bloc) JOIN dim_scrutin s USING (id_scrutin)
GROUP BY r.id_scrutin, b.libelle ORDER BY s.date_scrutin, b.ordre_affichage;
-- @nom: communes_ayant_change_de_bloc_2022_2024
SELECT a.libelle, a.code_bloc AS bloc_2022, b.code_bloc AS bloc_2024, c.population_2025
FROM v_resultats a JOIN v_resultats b ON a.code_commune = b.code_commune
JOIN dim_commune c ON c.code_commune = a.code_commune
WHERE a.id_scrutin = 'LEGI_2022' AND a.rang = 1 AND b.id_scrutin = 'LEGI_2024' AND b.rang = 1 AND
a.code_bloc <> b.code_bloc
ORDER BY c.population_2025 DESC;
-- @nom: vote_par_tranche_niveau_de_vie_2024
WITH nv AS (SELECT code_commune, valeur, NTILE(4) OVER (ORDER BY valeur) AS quartile
            FROM fait_socio_eco WHERE indicateur = 'NIVEAU_VIE_MEDIAN')
SELECT nv.quartile, ROUND(MIN(nv.valeur)) AS niveau_vie_min, ROUND(MAX(nv.valeur)) AS
niveau_vie_max,
       ROUND(AVG(CASE WHEN v.code_bloc = 'CENTRE' THEN v.part_pct END), 1) AS centre_pct,
       ROUND(AVG(CASE WHEN v.code_bloc = 'GAUCHE' THEN v.part_pct END), 1) AS gauche_pct,
       ROUND(AVG(CASE WHEN v.code_bloc = 'EXTREME_DROITE' THEN v.part_pct END), 1) AS
ext_droite_pct
FROM nv JOIN v_resultats v ON v.code_commune = nv.code_commune AND v.id_scrutin = 'LEGI_2024'
GROUP BY nv.quartile ORDER BY nv.quartile;
-- @nom: part_valeurs_estimees_delinquance
SELECT annee, ROUND(100.0 * AVG(est_estime), 1) AS pct_valeurs_estimees FROM fait_delinquance
GROUP BY annee ORDER BY annee;
-- @nom: projection_2027_communes_les_plus_peuplees
SELECT c.libelle, c.population_2025, p.code_bloc AS bloc_projete, ROUND(100 * p.part_predite, 1)
AS part_projetee_pct
FROM fait_prediction p JOIN dim_commune c USING (code_commune)
WHERE p.annee_cible = 2027 AND p.est_bloc_en_tete = 1 ORDER BY c.population_2025 DESC LIMIT 20;
```

Exemple de résultat : 203 communes ont changé de bloc en tête entre les législatives 2022 et 2024 ; les plus peuplées sont L'Isle-d'Abeau, Sassenage, Roussillon, Varces-Allières-et-Risset, Vif.

E Annexe – Document NoSQL

Extrait du document d'une commune.

```
{
 "_id": "38001",
 "libelle": "Les Abrets en Dauphiné",
 "population_2025": 6850,
 "groupe_typologie": 0,
 "socio_eco": {
  "niveau_vie_median_2021": 22650.0,
  "taux_pauvrete_2021": 11.0,
  "taux_chomage_2010": 0.0924,
  "taux_chomage_2015": 0.1374,
  "taux_chomage_2021": 0.0743
 },
 "resultats": {
  "EURO_2019": {
   "participation_pct": 48.73,
   "parts_pct": {
    "EXTREME_DROITE": 35.07,
    "GAUCHE": 28.02,
    "CENTRE": 17.83,
    "DROITE": 14.06,
    "AUTRES": 5.02
   }
  },
  "LEGI_2017": {
   "participation_pct": 45.18,
   "parts_pct": {
    "CENTRE": 30.54,
    "GAUCHE": 25.84,
    "EXTREME_DROITE": 24.74,
    "DROITE": 18.35,
    "AUTRES": 0.53
   }
  },
  "LEGI_2022": {
   "participation_pct": 45.66,
   "parts_pct": {
    "EXTREME_DROITE": 37.9,
    "GAUCHE": 27.04,
    "CENTRE": 21.61,
    "DROITE": 13.35,
    "AUTRES": 0.1
   }
  },
  "LEGI_2024": {
   "participation_pct": 68.23,
   "parts_pct": {
    "EXTREME_DROITE": 50.14,
    "GAUCHE": 21.96,
    "CENTRE": 19.06,
    "DROITE": 8.84
   }
  },
  "PRES_2017": {
   "participation_pct": 78.86,
   "parts_pct": {
    "EXTREME_DROITE": 34.54,
    "DROITE": 21.9,
    "GAUCHE": 21.9,
```

```
     "CENTRE": 19.4,
     "AUTRES": 2.26
    }
   },
   "PRES_2022": {
    "participation_pct": 76.58,
    "parts_pct": {
     "EXTREME_DROITE": 42.57,
     "GAUCHE": 26.47,
     "CENTRE": 20.53,
     "DROITE": 7.4,
     "AUTRES": 3.03
    }
   }
  },
  "projections": {
   "2027": {
    "bloc_en_tete": "EXTREME_DROITE",
    "parts": {
     "GAUCHE": 0.1959,
     "CENTRE": 0.216,
     "DROITE": 0.1217,
     "EXTREME_DROITE": 0.4663
    }
   },
   "2028": {
    "bloc_en_tete": "EXTREME_DROITE",
    "parts": {
     "GAUCHE": 0.1819,
     "CENTRE": 0.1909,
     "DROITE": 0.2543,
     "EXTREME_DROITE": 0.3729
    }
   },
   "2029": {
    "bloc_en_tete": "EXTREME_DROITE",
    "parts": {
     "GAUCHE": 0.2288,
     "CENTRE": 0.1779,
     "DROITE": 0.1687,
     "EXTREME_DROITE": 0.4246
    }
   }
  }
}…
```

F Annexe – Livrables et exécution

Où trouver chaque élément.

Livrable	Emplacement
Rapport final	rapport/
Support de soutenance	presentation/
Tableau de bord	tableau_de_bord/tableau_de_bord_isere.html
Entrepôt SQL et schéma	sql/
Version NoSQL	data_clean/nosql_communes.json
Code commenté	scripts/ (00 à 15)
Figures	figures/

Exécution complète : `python scripts/00_pipeline.py`. Tous les livrables sont déposés dans le dépôt GitHub du groupe.

G Annexe – Intégrité des sources

Empreintes SHA-256 des fichiers sources.

Fichier	Taille	Empreinte (début)
2017-legislatives-1_par_commune_long.csv.gz	2,9 Mo	6743e66e89b7f1ec483eb04c…
2017-presidentielle-1_par_commune_long.csv.gz	2,4 Mo	8dc849c8b50fd70c85c1e35a…
2019-europeennes_par_commune_long.csv.gz	5,7 Mo	5f884384bb5f71afcfd93b30…
DS_FILOSOFI_CC_data.csv	44,3 Mo	3ea3f522f3f9aa7da86af825…
base-cc-emploi-pop-active-2021.CSV	158,1 Mo	8a1bc8bcebdfa5fa152e661f…
legi2022_t1_subcom.xlsx	19,6 Mo	5e4640bab7250adfc2001c71…
legi2024_communes.xlsx	12,0 Mo	0bb8661b9a894020b77d34ea…
lexique nuance 2022.txt	0,0 Mo	e47a3051b9de171fe0da3a8c…
lexique nuance 2024.txt	0,0 Mo	f43e25ff0faf8bda46c719c7…
pres2022_t1_burvot.xlsx	33,5 Mo	cf323f2c5656725bc9bd0a99…
ssmsi_all.csv.gz	39,9 Mo	d96190b688fd185faac8234f…

H Annexe – Sources et glossaire

Références et vocabulaire.

- Données des élections, data.gouv.fr (ministère de l'Intérieur) : https://www.data.gouv.fr/fr/pages/donnees-des-elections/
- Données sécurité, data.gouv.fr (SSMSI) : https://www.data.gouv.fr/fr/pages/donnees-securite/
- Revenus et pauvreté des ménages en 2021, INSEE : https://www.insee.fr/fr/statistiques/7756729
- Emploi et population active en 2021, INSEE : https://www.insee.fr/fr/statistiques/8202916
- Dates de l'élection présidentielle 2027, Service-Public.fr : https://www.service-public.gouv.fr/particuliers/actualites/A15053

Terme	Définition
Accuracy	Part des prédictions correctes sur des données de test
Apprentissage supervisé / non supervisé	Avec / sans réponse connue pendant l'apprentissage
Arbre de décision	Suite de questions apprises qui mène à une réponse
COG	Code officiel géographique de l'INSEE
ETL	Extraire, transformer, charger
F1 macro	Moyenne sur les blocs de l'équilibre entre précision et rappel
Gradient Boosting	Arbres successifs corrigeant les erreurs des précédents
k-means	Algorithme qui regroupe des éléments semblables en k groupes
Matrice de confusion	Tableau croisant réalité et prédiction
Modèle en étoile	Tables de faits reliées à des tables de dimensions
Silhouette	Score de séparation des groupes, de −1 à 1
Spearman (ρ)	Corrélation de rang, de −1 à +1